

个人知识库问答和成长方向推荐平台

解决方案书

基于日常学习笔记、困难记录、阶段复盘和长期目标，提供可追溯的知识
问答、归纳总结与成长方向建议。

方案作者 潘力硕

版本 1.0

日期 2026 年 9 月

方案摘要

本方案将现有 Obsidian 个人知识库 RAG 衍生为面向个人长期成长的智能辅助平台。现有系统已经完成 Markdown、Frontmatter、标签和双向链接解析，支持增量向量索引、只读 Agent、结构化来源和 Obsidian 原笔记定位。衍生方案在这些能力之上增加困难分析、目标建模和成长方向推荐，使日常记录能够参与阶段规划。

平台坚持只读原则。系统可以分析笔记并提出建议，但不会直接创建、修改或删除 Vault 内容。事实判断必须返回来源；证据不足时说明无法确认。人生规划输出仅作为基于个人记录的参考，不替代职业、财务、医疗或心理领域的专业意见。

产品能力状态

能力层	当前基础	本方案新增内容	状态
知识接入	Markdown、Frontmatter、标签、双向链接	目标、困难和复盘的内容约定	基础已有
知识检索	增量向量索引、关联笔记、来源定位	按时间范围和目标范围组织证据	基础已有
知识问答	只读 Agent、证据门控、无证据拒答	主题总结和跨笔记归纳	基础已有并扩展
成长分析	每周复盘和待办示例笔记	困难模式、目标差距和行动建议	方案设计
反馈闭环	用户在 Obsidian 中维护内容	建议采纳、执行结果和下次复盘	后续演进

核心结论

该平台的可信度来自个人笔记证据和明确的系统边界。推荐模块不直接替用户作决定，而是解释建议依据、暴露信息不足，并把结果交回 Obsidian 供用户确认和记录。

用户问题与使用场景

目标用户持续使用 Obsidian 记录学习、项目和复盘，但知识积累与行动规划之间存在断点。笔记可以保存经历，却不会主动指出反复出现的困难，也不会自动把长期目标与近期行动联系起来。

主要问题

- 笔记持续增加后，用户难以快速确认自己已经形成哪些稳定认识。
- 困难分散在学习记录、项目日志和复盘，重复问题不容易被发现。
- 长期目标往往独立存在，缺少与当前能力证据和近期任务的对应关系。
- 通用模型可以给出建议，但不了解用户经历时容易生成空泛或不适用的规划。

典型提问

任务	示例问题	期望输出
知识问答	我之前为什么选择本地 Embedding	结论、引用片段和原笔记链接
总结归纳	总结最近一个月关于 RAG 的学习进展	主题脉络、已确认判断和未解决事项
困难分析	哪些技术问题在最近四周反复出现	困难主题、出现时间和对应来源
目标差距	距离 AI 解决方案岗位还缺少哪些证据	目标要求、已有积累和证据缺口
行动建议	下周应该优先补什么，为什么	建议动作、优先依据、来源和复盘日期

功能设计

知识库问答与总结

系统复用现有检索、阅读和关联发现工具。用户提出事实型问题时，Agent 先检索笔记，再根据来源生成回答。总结任务可以按主题、标签或时间范围汇总多篇笔记，并保留每项结论的来源。

困难模式分析

分析器从带有困难、阻塞、失败、待验证或复盘语义的记录中提取候选问题。系统按主题合并相近描述，记录首次出现、最近出现、重复次数和解决状态。单次情绪或孤立事件不会自动上升为长期短板。

目标与成长方向推荐

目标模块读取用户主动记录的长期目标和阶段目标，将其拆分为可观察的能力要求。推荐模块把这些要求与笔记证据、困难记录和近期复盘比较，形成优先级建议。每条建议都说明目标关联、已有依据、缺口判断、建议动作和需要再次检查的日期。

复盘闭环

平台只输出建议和来源。用户在 Obsidian 中决定是否采纳，并记录执行结果。下一次分析读取新的学习笔记和复盘，检查此前建议是否仍然适用。这样可以保留 Obsidian 的编辑体验，也避免模型静默改变个人资料。

建议输出结构

字段	含义	示例
关联目标	本建议服务的长期或阶段目标	AI 解决方案岗位
观察证据	来自笔记的事实与来源	项目文档和云端训练记录
差距假设	根据证据作出的可复核判断	缺少客户方案演示材料
建议动作	下一周期可完成的具体事项	制作一份十分钟方案演示
不确定性	缺失信息或相互冲突的记录	暂无真实客户反馈

服务流程与推荐规则

端到端流程

- 用户继续在 Obsidian 中记录学习内容、遇到的困难、阶段复盘和长期目标。
- 增量索引识别新增和变化笔记，复用未变化的 Chunk 与向量。
- 查询规划器将请求限制为检索、读取或关联发现，并由执行层校验参数。
- Retriever 汇集相关片段、标签、时间信息和双向链接，形成证据包。
- 知识任务生成带来源的回答或总结；成长任务进一步比较目标与当前证据。
- 系统返回建议、依据、不确定性和原笔记链接，用户确认后自行更新笔记。

推荐规则

规则	处理方式	目的
证据优先	事实结论必须绑定真实笔记片段	限制无来源判断
时间敏感	近期复盘权重高于过时计划，但保留历史变化	避免使用失效目标
重复验证	长期困难至少需要多条记录支持，孤立事件单独呈现	避免过度归因
目标约束	建议必须对应用户明确记录的目标或请求	减少泛化建议
冲突暴露	笔记存在矛盾时并列来源并请求用户确认	保留用户判断权
安全退出	证据不足时返回缺失信息，不生成确定性规划	控制建议风险

建议优先级

优先级由目标重要程度、时间约束、困难重复程度、现有能力差距和行动成本共同决定。第一版采用可解释规则并展示各项依据，不使用无法核验的综合分数。

系统架构

系统沿用现有 Retriever 合同和只读 Agent 边界。成长分析作为独立服务层读取检索结果，不直接访问 Vault 文件，也不获得写入工具。

层级	组件	职责	状态
数据层	Obsidian Vault	保存 Markdown、标签、双向链接和时间信息	已有
解析层	Scanner 与 Chunker	解析元数据并按内容哈希识别变化	已有
检索层	Embedding、JSON Snapshot、Retriever	提供语义检索和关联扩展	已有
服务层	FastAPI 与只读 Agent	承载搜索、问答、来源返回和原笔记定位	已有
分析层	总结器、困难分析器、目标差距分析器	从证据包生成结构化分析	衍生设计
推荐层	Growth Recommender	生成带依据和不确定性的行动建议	衍生设计
交互层	本地页面与 Obsidian URI	展示结果并返回原笔记	已有并扩展

数据流

权威数据始终是 Obsidian 中的原始 Markdown。向量索引属于可再生的派生数据；成长画像和建议也属于可重新计算的分析结果。用户修改原笔记后，系统通过增量索引更新证据，并在下一次请求时重新生成结论。

技术选型

当前服务使用 FastAPI、LangChain 只读工具和 Ollama bge-m3。JSON 索引在服务启动后加载到内存，数据增长后可以新增 pgvector Retriever。查询规划采用受限 JSON Schema 与安全回退；LoRA 只调整计划格式，不提供知识事实。

数据模型与接口设想

成长分析对象

对象	关键字段	来源与约束
NoteEvidence	note_id、path、title、tags、heading、snippet、updated_at	来自自己扫描笔记，不保存越界文件
Goal	title、time_horizon、priority、status、evidence_refs	只读取用户主动记录的目标
Difficulty	topic、occurrences、first_seen、last_seen、resolution_status	每项判断保留来源列表
Recommendation	goal、action、reason、evidence_refs、uncertainty、review_date	作为派生结果，不写回 Vault

建议接口

接口	用途	关键返回
GET /v1/summary	按主题和时间范围归纳笔记	summary、open_questions、sources
POST /v1/difficulties	识别重复困难和解决状态	themes、occurrences、sources
POST /v1/growth-review	比较目标、积累和困难	gaps、recommendations、uncertainties、sources
GET /v1/recommendations/{id}	查看一次建议的依据	goal、actions、evidence、review_date

这些接口属于本方案的衍生设计，不代表现有仓库已经提供。第一版可以先复用当前 /v1/search、/v1/chat 和 /v1/notes/{note_id}，在服务层验证分析流程后再固化新接口。

查询规划 LoRA 的定位

现有训练留档证明 Qwen2.5-3B 查询规划 LoRA 的数据生成、训练、权重校验和日志归档流程可以复现。该模型只生成受限查询计划，不能提供知识事实。当前测试集只有 4 条，尚未完成同一推理端点下的基座与 Adapter 对照，因此不声明准确率或业务指标提升。

隐私与安全设计

只读边界

Agent 只开放 search_notes、read_note 和 find_related_notes。所有路径经过 Vault 根目录校验；系统不提供创建、修改、移动或删除笔记的接口。成长建议也只作为响应返回。

证据和日志

- 知识结论与成长判断分别标记事实、推断和建议，来源由 API 结构化返回。
- 无工具证据或检索结果为空时返回 no_evidence，不接受模型自由生成的知识结论。
- 访问日志只保留方法、路径、状态、耗时和来源数量，不记录问题或笔记正文。
- 真实 Vault、模型密钥和生成索引不进入仓库；公开演示使用脱敏示例数据。

部署方式

方式	组件位置	适用条件	注意事项
全本地	Vault、Embedding、聊天模型均在本机	隐私优先且具备本地算力	需要维护模型资源
本地检索	Vault 与索引本地，聊天模型使用兼容 API	降低本地推理成本	仅发送必要片段并确认服务条款
私有环境	服务和模型部署到个人专属服务器	需要跨设备访问	补充身份认证、传输加密和备份

规划建议边界

平台只根据用户记录提供参考。涉及求职、财务、健康或心理状态时，系统应提示信息范围和不确定性；当问题需要专业判断或存在明显风险时，停止给出确定性行动方案。

实施路线

实施过程优先验证分析质量和证据闭环，不改变现有知识库的编辑模式。每个阶段都可以独立验收。

阶段	交付内容	验收重点
现有基础	扫描、增量索引、搜索、问答、关联发现和 Obsidian 定位	核心只读流程可运行
内容约定	目标、困难、复盘的 Frontmatter 与写作模板	字段可选，旧笔记继续兼容
总结分析	主题总结、未解决事项和困难模式提取	每项结论可以回到来源
成长推荐	目标差距分析、建议结构和不确定性说明	建议依据完整，证据不足时退出
复盘反馈	采纳状态、执行结果和复查日期	用户主动记录，系统不自动写入
评测演示	脱敏测试集、演示脚本和评价报告	报告保留样本量与限制

最小可行版本

第一版新增两个只读能力：按主题和时间总结笔记，以及根据一个明确目标生成成长复盘。困难识别先使用可解释规则和结构化提示词，不引入复杂画像系统。推荐结果不保存到独立数据库，用户仍在 Obsidian 中决定是否记录。

主要风险

风险	影响	控制措施
笔记样本偏少	建议可能受少量记录影响	展示样本范围并请求补充信息
目标描述模糊	差距判断缺少比较基准	要求用户确认目标和时间范围
模型过度归因	把单次困难解释为长期短板	设置重复证据门槛并保留不确定性
私人内容外泄	敏感经历进入外部服务	本地优先、最小片段和可配置脱敏

验收与评测

功能验收

能力	验收条件
知识问答	知识性结论带来源；没有来源时返回 no_evidence；链接可以定位原笔记
总结归纳	输出已确认结论和待解决事项，并能逐项查看来源
困难分析	重复困难显示时间和来源；孤立记录不会自动判定为长期问题
成长建议	每条建议包含关联目标、证据、理由、不确定性和复查日期
安全边界	所有 Agent 工具保持只读，越界路径和非法参数被拒绝
隐私	日志不记录问题正文、回答正文、笔记正文或模型密钥

评价指标

指标	口径	说明
来源覆盖率	含知识结论的输出中，具备有效来源的比例	目标值在测试集确定后设定
无依据断言率	人工复核发现没有来源支持的事实判断比例	应优先控制为零
困难合并准确性	人工判断同一主题是否被正确聚合	报告样本数和分歧案例
建议可执行性	用户对动作是否具体且能在复查日前完成的评分	不等同于长期效果
建议采纳率	用户主动记录为已采纳的建议占比	只用于个人反馈，不代表因果效果

评测原则

公开演示使用脱敏或合成笔记。任何准确率、召回率或建议效果都必须来自固定测试集和真实运行报告，并同时说明样本量、模型版本和数据范围。查询规划 LoRA 的现有训练损失不能解释为业务效果提升。

演示方案

演示使用独立的脱敏 Vault，不读取真实私人笔记。准备目标、学习、困难和复盘四类笔记，使观众能够看到系统如何从分散记录形成可核对的成长建议。

步骤	演示动作	观察点
1	展示目标笔记和近期学习记录	说明权威数据仍保存在 Obsidian
2	提问过去一个月关于 RAG 的主要进展	回答归纳多篇笔记并列出来源
3	询问反复出现的困难	系统展示出现时间、相关项目和解决状态
4	要求结合长期目标推荐下周行动	建议包含目标、证据、理由和不确定性
5	点击来源返回 Obsidian 原笔记	验证结论可以人工核对
6	询问知识库不存在的问题	系统返回证据不足而不是编造答案

示例输出

建议动作：制作一份十分钟 AI 方案演示，并邀请一名同学按客户角色提出问题。依据：目标笔记要求补充售前表达能力，近期项目记录已经具备架构与交付材料。限制：知识库中没有真实客户反馈，因此本建议只能验证演示准备能力。复查日期：下一次周复盘。

演示成功标准

- 观众能够区分现有检索能力与成长推荐的衍生设计。
- 每个关键结论都能回到一篇或多篇原始笔记。
- 系统在证据不足时明确停止，不通过语言流畅度掩盖信息缺口。

证据边界与演进方向

已有工程证据

- 现有仓库已经实现 Obsidian Markdown 解析、增量索引、Retriever、只读 Agent、FastAPI 接口和结构化来源返回。
- 路径边界、日志脱敏、无证据拒答和工具白名单已经进入设计与测试范围。
- 查询规划 LoRA 已完成一次云端训练、权重校验和日志归档，但尚无可用于声明效果提升的对照结果。
- 示例 Vault 已包含学习记录、项目复盘、每周复盘和下一步事项，可作为成长分析的内容基础。

本方案新增设计

- 目标与困难的结构化表达，以及跨时间记录的聚合规则。
- 知识总结、困难模式、目标差距和行动建议的统一输出结构。
- 成长建议的证据门槛、不确定性说明和复查机制。
- 面向演示的脱敏数据、评价指标和阶段验收方案。

后续方向

后续可以先完成脱敏原型和人工评测，再决定是否增加时间轴、建议历史和可视化成长轨迹。数据量明显增长后再评估 pgvector；只有固定测试集能够证明查询规划模型有效时，才考虑将 LoRA 接入默认路径。

产品定位

平台以个人记录为证据，帮助用户回顾知识、识别困难并形成下一阶段的行动建议。它保留 Obsidian 作为内容权威和编辑入口，把 AI 限制在检索、分析和建议范围内。